Dal CT longitudinale al futuro latente

Dataset NLST, foundation model, prognosi e world model COLIPRI

Riunione di progetto

23 settembre 2026

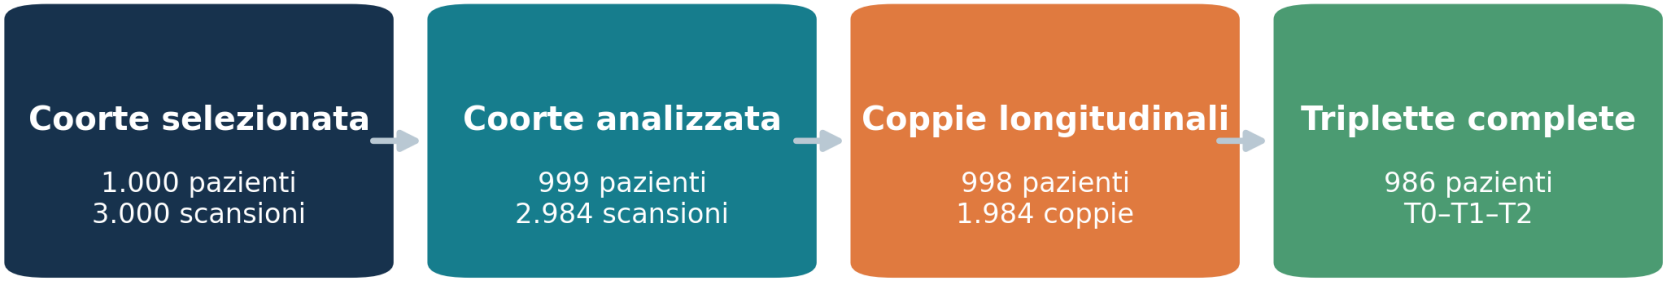
Messaggio principale

- COLIPRI contiene informazione clinica forte e accessibile con probe semplici.
- Il **futuro reale** è molto più prognostico dello stato corrente, soprattutto a 1–2 anni.
- I world model ricostruiscono una parte del cambiamento, ma recuperano solo una piccola parte del vantaggio prognostico.
- L’evidenza punta verso un limite di **segnale/dati/target**, non verso una semplice mancanza di capacità

Il percorso sperimentale

1. Costruire una coorte longitudinale affidabile e label landmark-safe.
2. Verificare quali foundation model producono stati clinicamente decodificabili.
3. Misurare l’upper bound: presente osservato vs futuro osservato.
4. Predire il futuro latente con modelli piccoli e controllati.
5. Separare ricostruzione, conservazione dell’informazione e valore della storia.

Dataset: coorte NLST selezionata



Split fisso a livello paziente: 599 train / 200 validation / 200 test

Costruzione dei dati e controllo del leakage

- Split fisso a livello paziente: **599 / 200 / 200**.
- Tutte le normalizzazioni, PCA e statistiche dei delta sono fit solo sul train.
- Stesse coppie e stessi pazienti per i confronti fra rappresentazioni.
- Encoder congelati; checkpoint selezionati solo su validation.
- Il test è già stato ispezionato: non è validazione esterna.

Label diagnostiche: stato osservato nella scansione

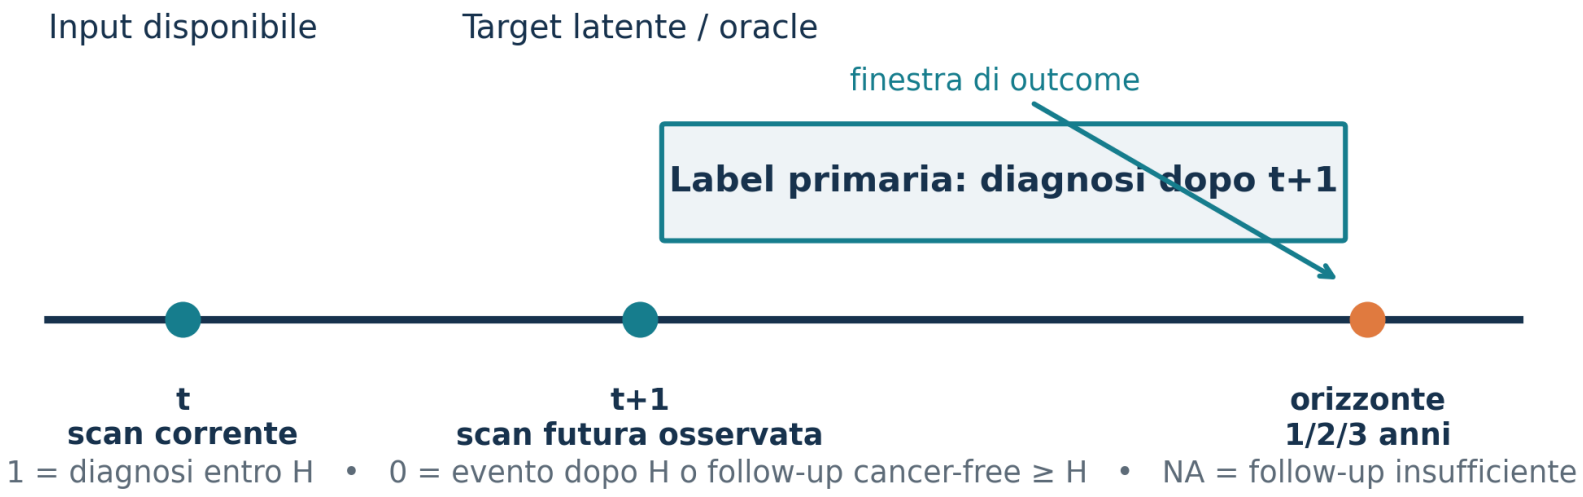
Derivate dai metadati NLST di lettura radiologica e anomalie CT:

- `isolation_suspicious` — prevalenza 39,0%
- `nodule_ge_4mm` — 38,8%
- `emphysema` — 41,5%
- `fibrosis_or_scarring` — 25,1%

Uso nel progetto:

- validare la qualità della rappresentazione congelata;
- misurare il recupero futuro contro la

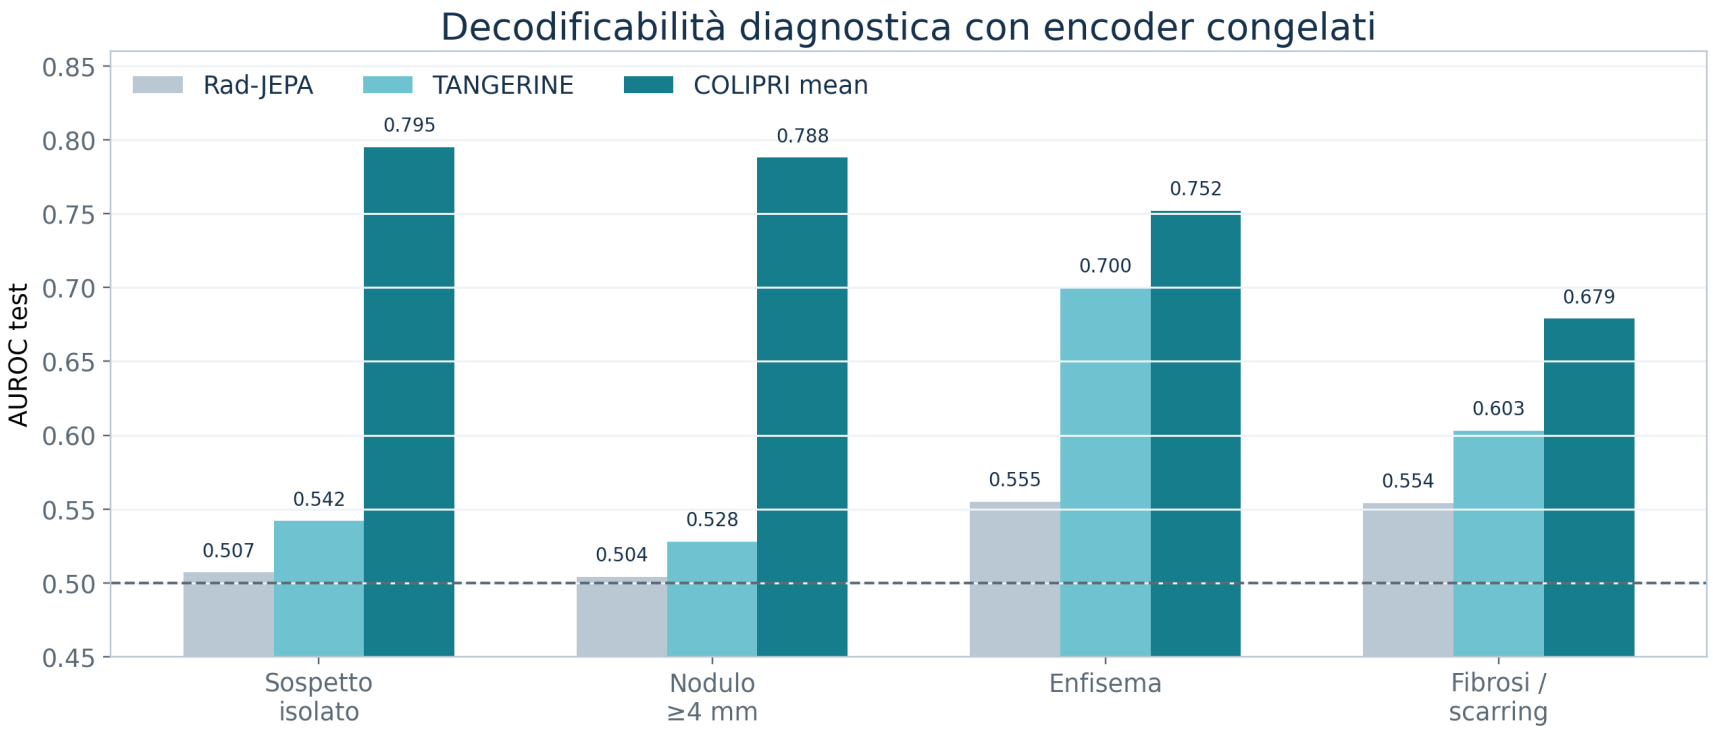
Label prognostiche: landmark dopo la scansione



Distribuzione delle classi: il nodo temporale

Endpoint post-t+1	Train	Validation	Test
1 anno	107 / 1.186 (9,0%)	33 / 394 (8,4%)	31 / 396 (7,8%)
2 anni	256 / 1.181 (21,7%)	81 / 391 (20,7%)	75 / 396 (18,9%)
3 anni	364 / 1.173 (31,0%)	112 / 389 (28,8%)	113 / 396 (28,5%)

Foundation model esplorati



Rad-JEPA-3D: primo baseline

- Input a finestre 3D da 32 slice; feature token da 384 dimensioni.
- Aggregazioni: resize, sliding mean/max/mean-max, gated attention.
- 100 run complessivi, split e scaling train-only.
- Risultato: sospetto e nodulo ≈ chance; segnale debole per enfisema e fibrosi.
- Migliori AUROC: **0,508 / 0,506 / 0,555 / 0,564**.

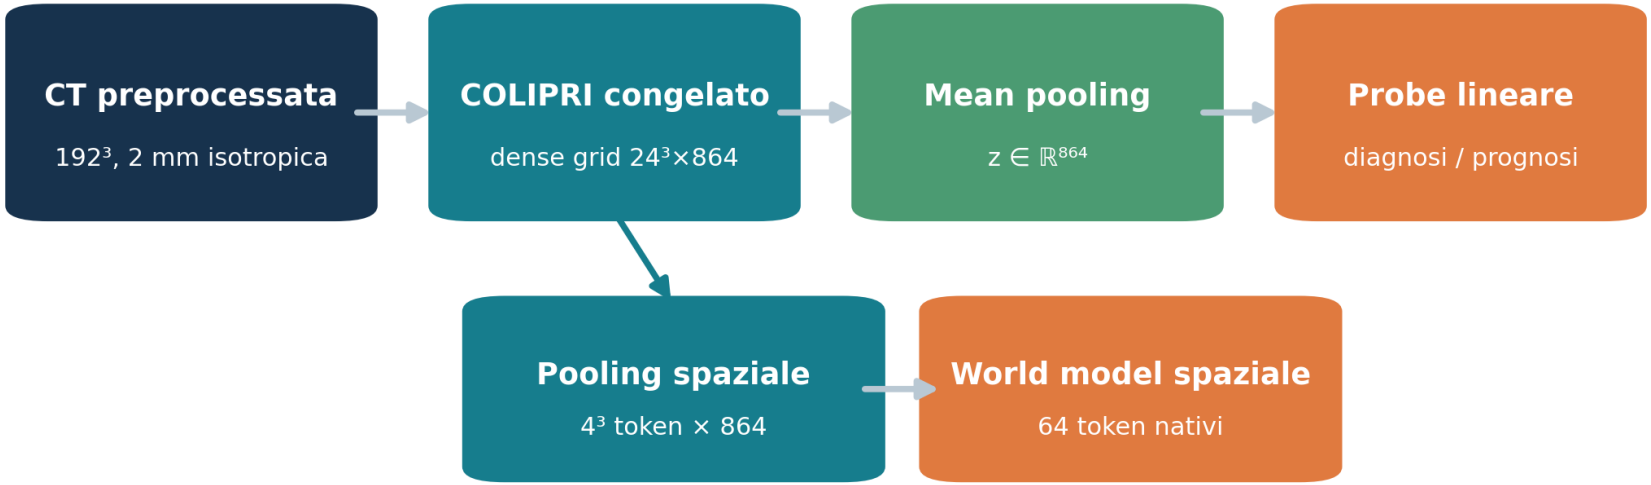
TANGERINE: salto parziale

- ViT-L, volume 256^3, 4.096 patch token, embedding globale 2.048-d.
- Miglioramento netto per enfisema: AUROC **0,700**.
- Miglioramento moderato per fibrosi: **0,603**.
- Sospetto e nodulo restano deboli: **0,542 / 0,528**.
- MLP downstream non migliore del probe lineare.
- Caveat: pretraining NLST-LSS; overlap

Perché abbiamo scelto COLIPRI

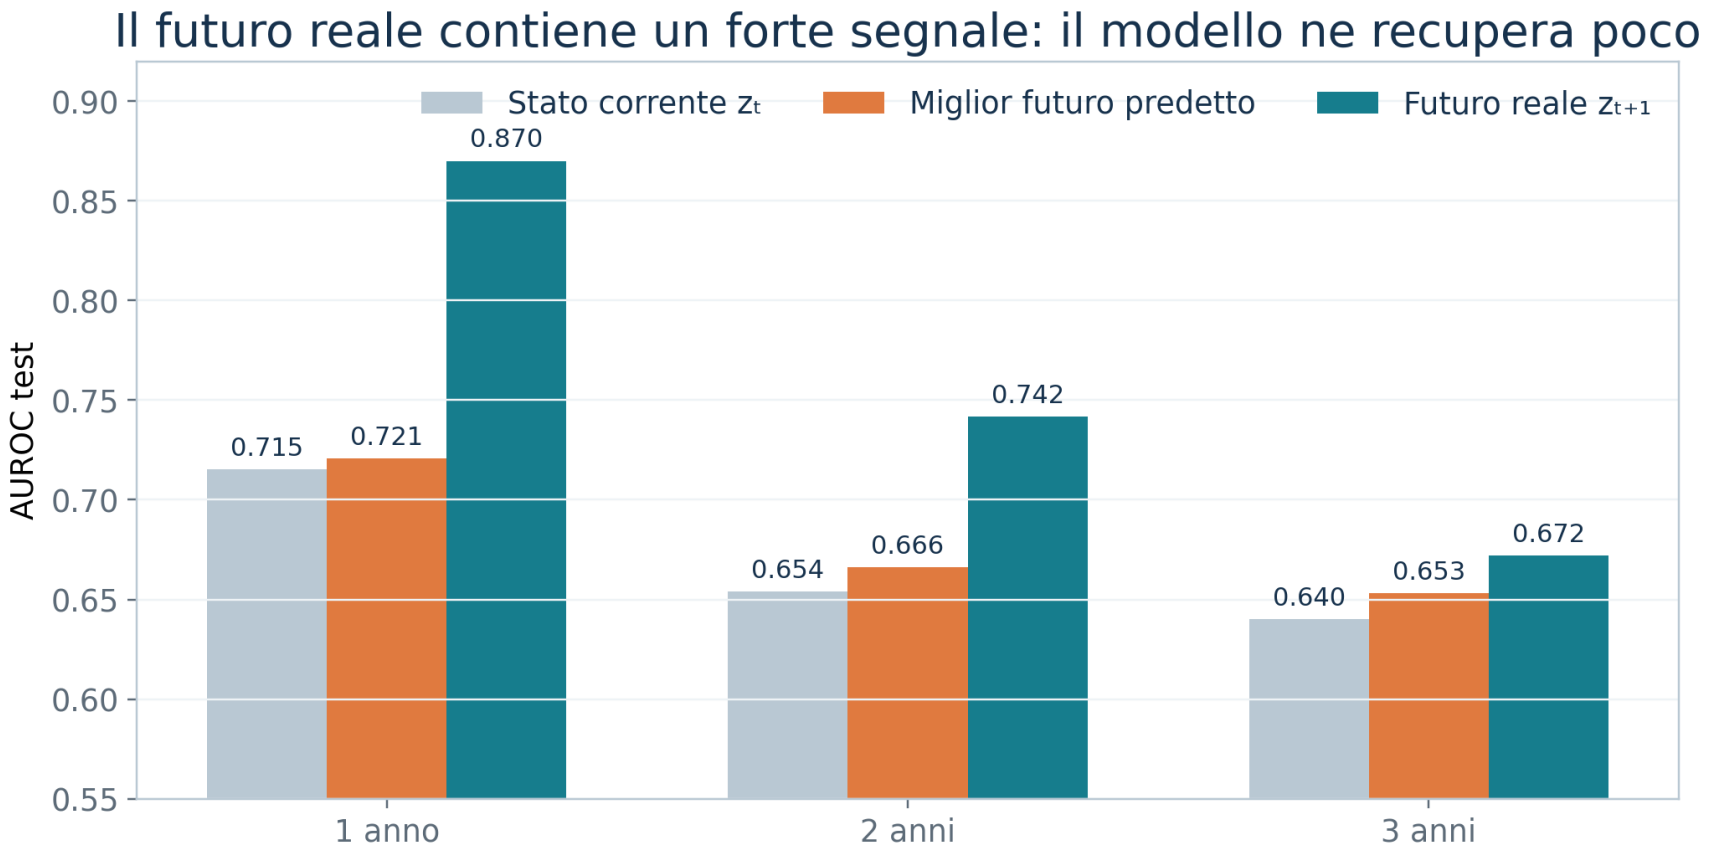
- Dense feature grid nativa: `[24,24,24,864]`.
- Preprocessing ufficiale: RAS, 2 mm isotropico, crop/pad 192^3.
- Mean pooling 864-d è il miglior aggregatore diagnostico.
- AUROC: sospetto **0,795**, nodulo **0,788**, enfisema **0,752**, fibrosi **0,679**.
- Offre sia uno stato globale compatto sia token spaziali per esperimenti successivi.

Come è costruita la rappresentazione del volume



Sanity check: mean(64 token) ≃ embedding COLIPRI mean-pooled (MSE $1{,}32\times10^{-16}$)

Esperimento chiave: il futuro reale è più prognostico?



Domanda del world model

Possiamo trasformare lo stato corrente in uno stato futuro predetto che sia più prognostico, senza usare label cliniche nel training della transizione?

Confronto primario:

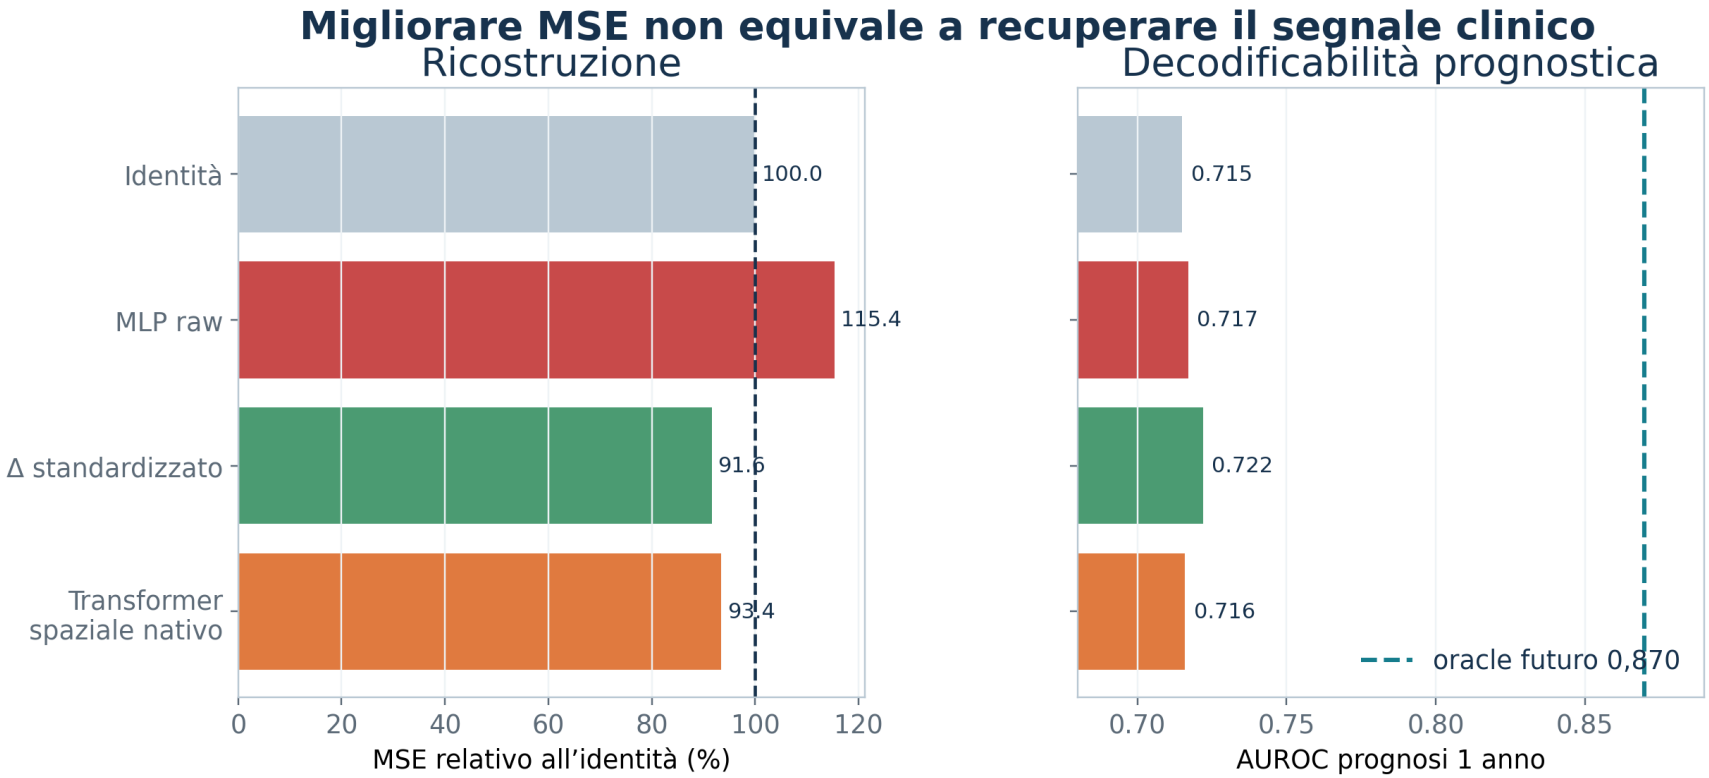
$z_t \rightarrow \hat{z}_{t+1} \rightarrow z_{t+1}$ reale

- forecasting latente: MSE, cosine, L2, delta cosine;
- prognosi: AUROC, AUPRC, MCC, F1 a 1/2/3 anni;
- diagnosi futura: quattro target contro le stesse label t+1.

Prima architettura: residual MLP



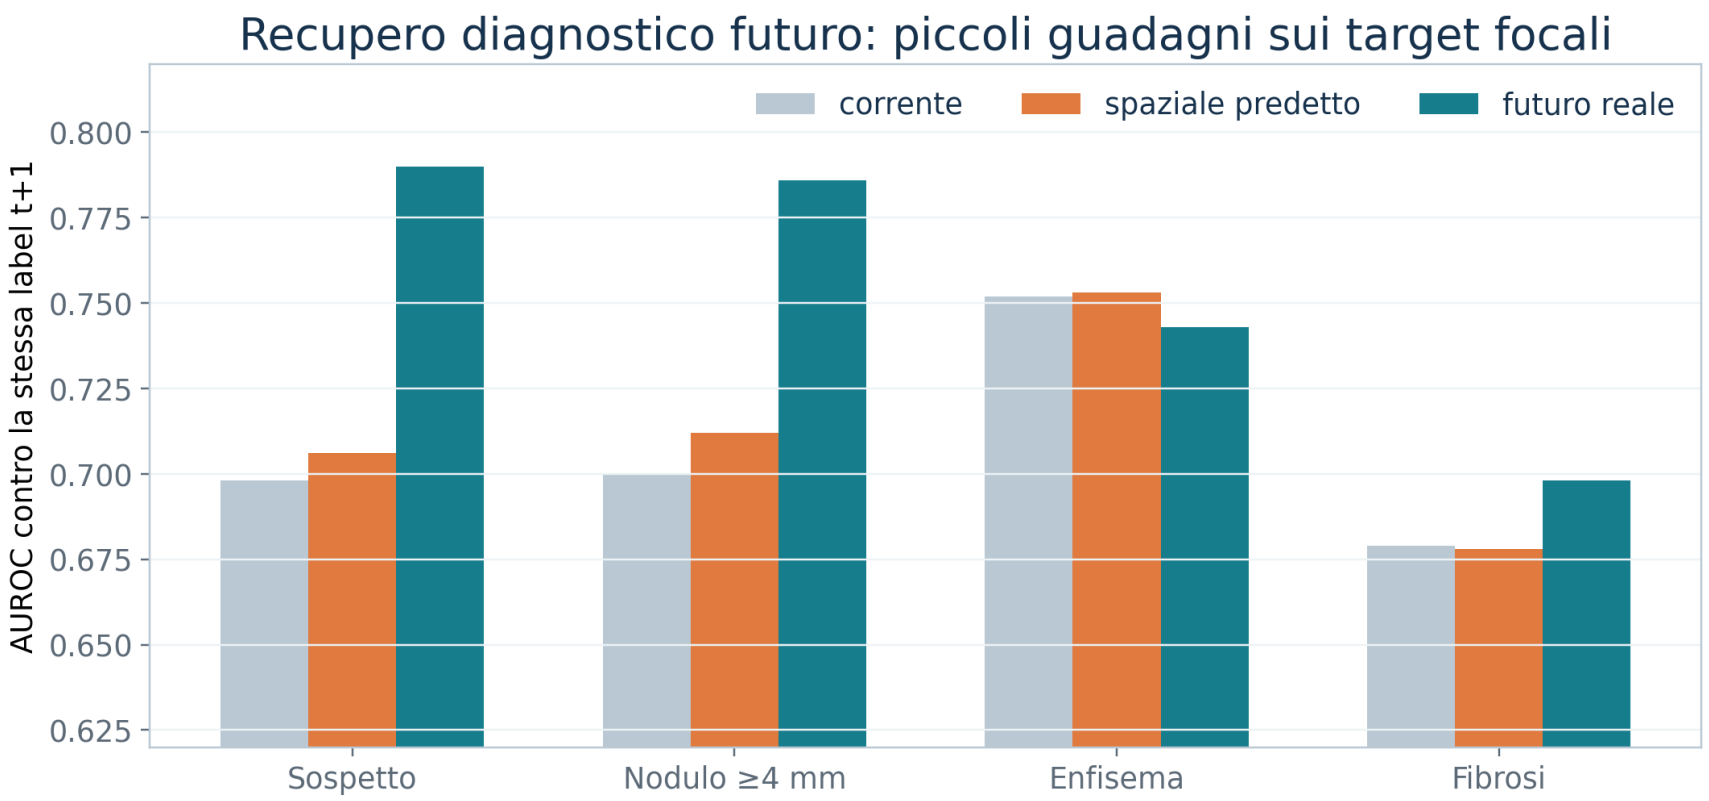
Ablation dell’obiettivo: cosa è migliorato



Modelli spaziali: PCA-256 vs spazio nativo

- Dense grid → mean pooling spaziale → 64 token.
- PCA-256: ricostruzione migliore, ma oracle clinico indebolito.
- Nativo 864-d: 3 blocchi, 8 head, senza PCA.
- Il modello nativo riduce la token-MSE del **6,6%** vs identità, ma la prognosi resta ≈ MLP pooled.
- AUROC 1y/2y/3y: pooled MLP **0,717/0,667/0,654**; nativo **0,716/0,668/0,652**

Diagnostica futura stretta



Adapter temporali: risultato e audit del codice

- Adapter iniziale: `864 → 256 → 128`, predictor residuale nel latent space.
- Ricostruzione interna molto buona, prognosi inizialmente ≈ chance.
- Audit: export di training mescolato, label in ordine manifest → **risultati downstream iniziali invalidi**.
- Rivalutazione corretta: bottleneck ancora debole, ma non catastrofico.
- Tutti i 30 checkpoint originali avevano **SIGReg disabilitato**.

Adapter di preservazione e SIGReg

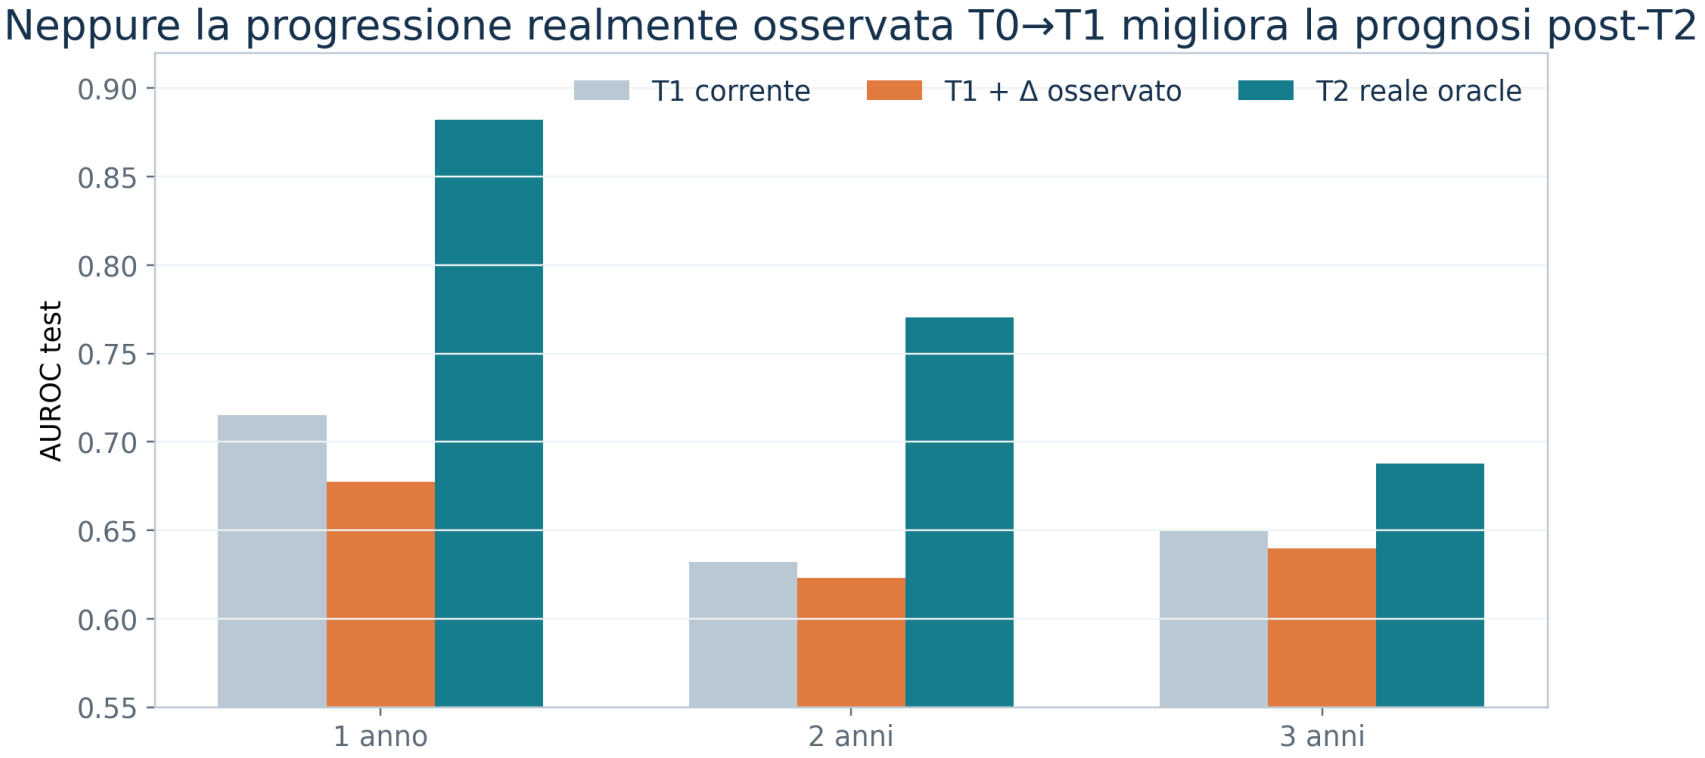
- Adapter residuale 864-d inizializzato all’identità.
- Due fasi: preservazione, poi transizione con adapter congelato.
- Bottleneck 256/512 e SIGReg con probe matched.
- Il residuale preserva quasi esattamente la prognosi corrente.
- SIGReg non produce un guadagno stabile; i bottleneck perdono o non aggiungono informazione.
- Predatto nativo/residuale/SIGReg

Supervisione prognostica sull’adapter

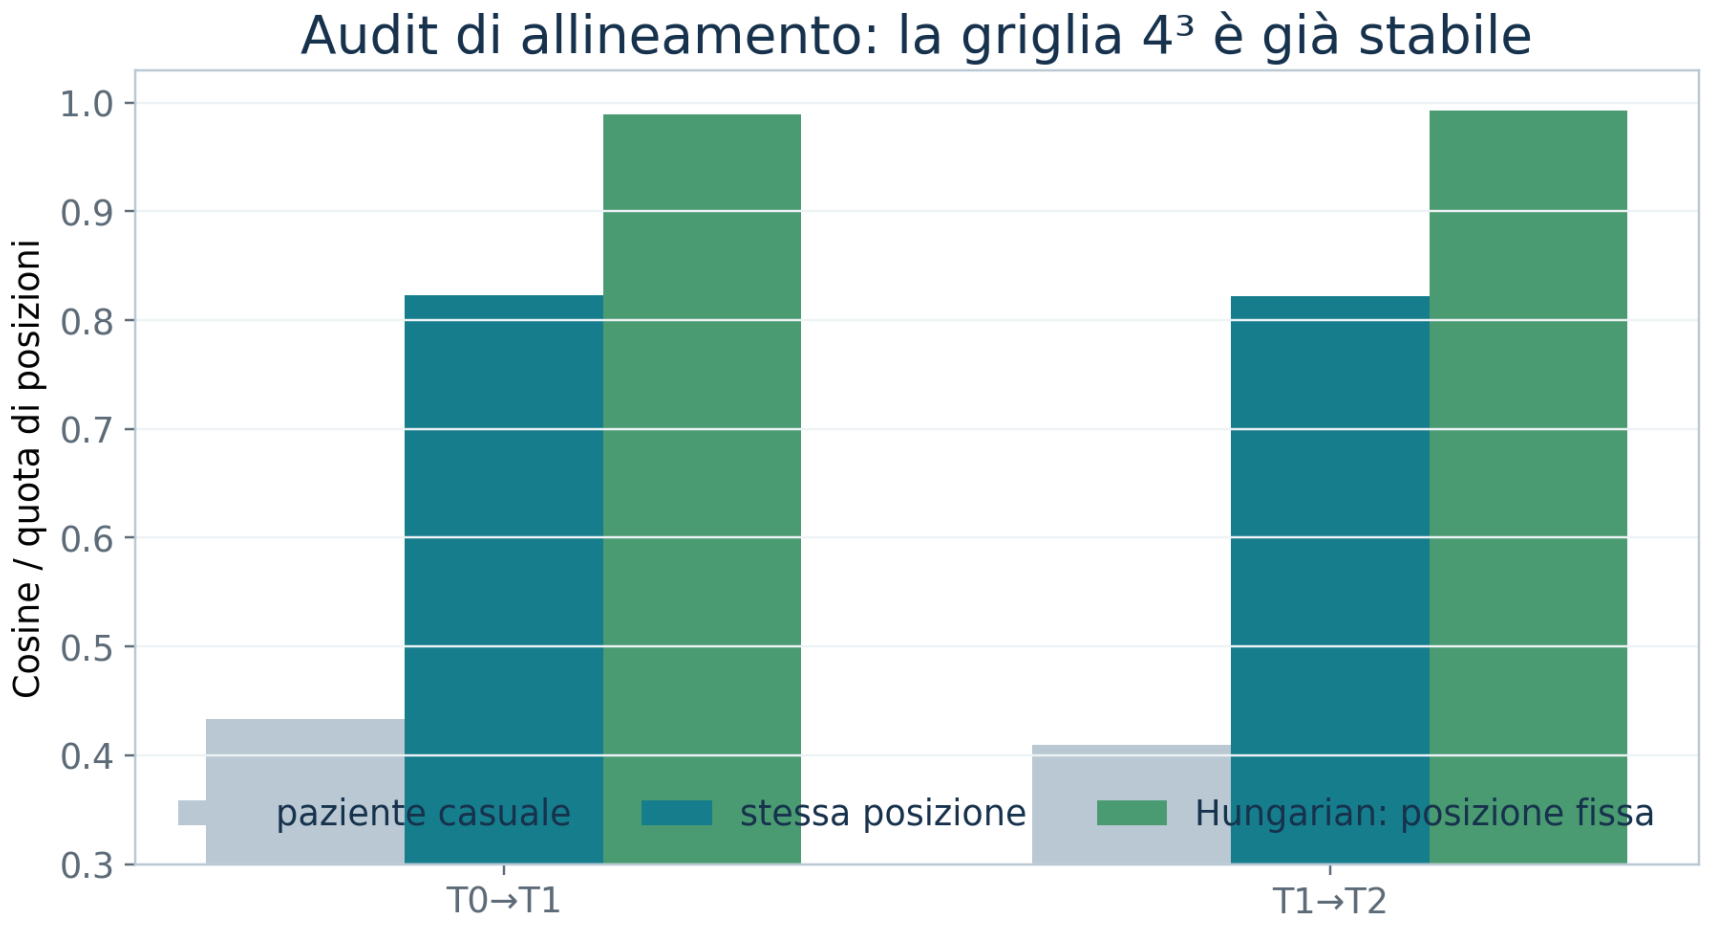
- Adapter residuale 864-d con BCE 1/2/3 anni + ricostruzione + anchor.
- Nessun futuro, delta o round negli input.
- Test pooled, probe congelato:
  - COLIPRI corrente: **0,715 / 0,654 / 0,640**
  - adapter joint: **0,713 / 0,654 / 0,641**
- La testa lineare diretta resta competitiva; nessun vantaggio robusto.

Interpretazione: il limite non si risolve con una piccola deformazione supervisionata dello stesso stato

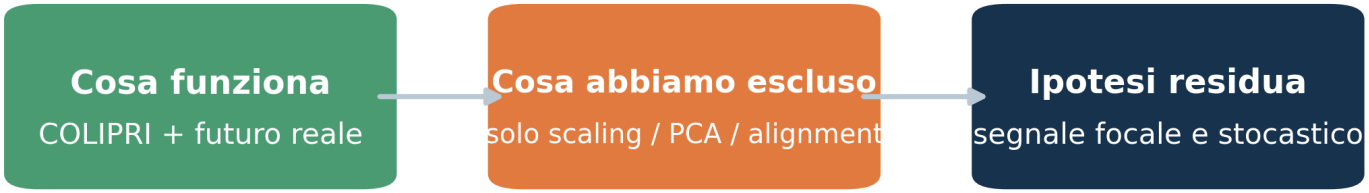
La storia osservata aiuta davvero?



Audit di allineamento dei token



Cosa abbiamo imparato



- diagnostica forte
- oracle prognostico forte
- identità difficile da battere

- MSE migliore ≠ AUROC migliore
- Transformer ≈ MLP pooled
- SIGReg non risolve

- cambiamenti piccoli/lesionali
- vicinanza alla diagnosi
- dati e confondimento temporale

Direzione: predire/rankare cambiamenti clinicamente rilevanti, non ricostruire tutto l’embedding

Direzione più promettente

1. **Riformulare il target clinico-temporale**
   - landmark a T1 con outcome dopo T1; lag minimo dalla diagnosi;
   - coorte non pooled per round o sampling bilanciato per transizione.
2. **Rappresentazione locale/lesion-aware**
   - token a risoluzione più fine, candidate region/nodule tokens;
   - global state + top-k cambiamenti focali.
3. **Obiettivo discriminativo controllato**

Prossimo esperimento minimo e informativo

Studio lesion-aware con controllo matched

- Input: COLIPRI globale + token locali ad alta risoluzione da T0/T1.
- Target: rischio post-T1, con esclusione/stratificazione per diagnosi entro 90–180 giorni.
- Modelli: current-only vs current+storia, stessa capacità.
- Nessuna previsione completa dell’embedding nella prima fase.

Limiti da mantenere visibili

- Coorte case-control arricchita; probabilità non interpretabili come rischio assoluto.
- Test riutilizzato durante lo sviluppo; risultati non esterni.
- Possibile overlap NLST con il pretraining di TANGERINE/COLIPRI.
- Label diagnostiche read-level, non segmentazioni.
- ~2.000 coppie; solo 2 positivi T0→T1 nel test 1y.

Conclusione

Abbiamo trovato un buon spazio clinico e un forte oracle futuro; non abbiamo ancora trovato una dinamica prevedibile che trasferisca quel vantaggio al presente.

- La persistenza è un baseline difficile da battere.
- Il delta medio è prevedibile, il delta prognostico molto meno.
- Più capacità non è ancora la risposta supportata dai dati.
- Prossimo salto: **localizzazione, endpoint e segnale clinicamente mirato**

Appendice — riepilogo numerico

Esperimento	Risultato principale
COLIPRI diagnostica	AUROC 0,795 / 0,788 / 0,752 / 0,679
Futuro reale vs corrente	1y: 0,870 vs 0,715; 2y: 0,742 vs 0,654
Delta standardizzato	MSE −8,4% vs identità; AUROC +0,005/+0,012/+0,013
Transformer spaziale nativo	token-MSE −6,6%; prognosi ≈ pooled MLP
Adapter residuale/SIGReg	preserva, non migliora stabilmente
Storia T0→T1 osservata	nessun vantaggio vs current-only
Audit allineamento	forte corrispondenza; non è il bottleneck

Appendice — tracciabilità e riproducibilità

- PyTorch Lightning, W&B, checkpoint per seed.
- Manifest con patient/pair IDs e fingerprint degli input.
- Predizioni ed embedding esportati per seed, senza media primaria.
- Scaler, PCA e statistiche dei delta salvati e fit train-only.
- Smoke test GPU e controlli di shape/ordine prima dei run completi.
- Report completi in `docs/`; risultati

Appendice — documenti sorgente

- Dataset e label: `docs/nlst_*dataset_report.md`, `docs/nlst_prognostic_labels_report.md`
- Foundation model: `docs/nlst_*decodability_report.md`
- Oracle futuro: `docs/nlst_colipri_future_state_prognosis_report.md`
- World model: `docs/nlst_colipri_*world_model*_report.md`